멀티모달 AI · 중간고사 단일 페이퍼

01 · 기초와 CLIP

1강 / 2강 pp.4–43

Modality=표현·지각 방식. Raw(픽셀/파형)→abstract(객체/의미). 멀티모달 이유: 인간 경험·실제 응용·데이터 확장. **Foundation model**=대규모 자기지도 사전학습→다양한 downstream task.

Profile: distribution·granularity·structure·information·noise. p17 종합 **6축**: representations/distributions/structure/information/noise/**relevance**(과제·문맥). **BoW는 순서 소실.**

CLIP = Contrastive Language–Image Pre-training

400M image–text pairs. image encoder(ViT/ResNet)+text Transformer(EOT/causal/77)→공통 공간.
ViT=patch→linear+pos→Transformer/CLS. 정규화 벡터의 내적=cosine.
CLIP은 문장 생성보다 **짝 맞추기**.

$S_{ij}=I_i\cdot T_j/\tau$ (I,T: L2 정규화)
$L_{I\to T}=-(1/N)\Sigma_i\log[e^{S_{ii}}/\Sigma_j e^{S_{ij}}]$
$L_{T\to I}=-(1/N)\Sigma_i\log[e^{S_{ii}}/\Sigma_j e^{S_{ji}}]$
$\mathbf{L=(L_{I\to T}+L_{T\to I})/2}$

N×N: 행=image, 열=text. 대각 양성 N개, 음성 N(N−1)개. **행·열 CE 모두**. τ↓→softmax 더 뾰족. 균일 점수면 L=ln N. SimCLR 양성=같은 이미지의 두 view.

Zero-shot / 평가

"a photo of a {class}"→T_k; $\hat{y}=\text{argmax}_k\ I\cdot T_k$. 텍스트 특징=분류기 가중치. 여러 템플릿 평균=prompt ensemble. **Zero-shot**: 타깃 라벨 추가학습 없음. **Linear probe**: encoder 고정+head 학습. **Fine-tune**: encoder도 갱신.

02 · 강건성·SigLIP·한계

2강 pp.45–72

Effective robustness: 원래 분포 성능을 감안한 shift 저항. 통계 실험의 핵심 원인=**학습 데이터 분포**. 언어 감독·규모·prompt·대조 손실만으로 설명 X. 혼합 강건성은 가산 X, 분포 사이 보간. **R(YFCC)<R(혼합)<R(LAION)**.

SigLIP = 쌍별 sigmoid 이진 손실

$z_{ij}=+1$(짝), -1(비짝); $s_{ij}=t\ I_i\cdot T_j-b$
$\mathbf{L=(1/B)\Sigma_{i,j}\log[1+\exp(-z_{ij}s_{ij})]}$
b 부호: 2강 p.59 원본 기준; t,b 학습 가능.

배치 전역 softmax 분모 없음→분할/분산·메모리 효율. **음성쌍은 여전히 필요.** 작은 batch에서 유리, 큰 batch에서 유사한 경향.

장점: 싼 내적→검색·확장, open vocabulary.
한계: 관계/세부 개념→hard negatives; 이미지 전체 캡션의 지역성 부족 **→region caption+box**.

DataComp=데이터 필터 중요, 큰 데이터≠항상 좋음. **Meta CLIP 2**=다국어 확장. **Perception Encoder**=좋은 특징은 중간 층에도 존재.

03 · 적은 데이터로 CLIP 적응

3강 pp.4–54

Engineering=사람이 문구 선택. **Learning**=연속 prompt 벡터 학습. 작은 데이터의 무작정 full FT는 과적합 위험. **Frozen 가중치도 gradient 경로는 통과 가능.**

방법	변경/학습 대상	핵심
CoOp	text context $v_{1:M}$	고정 문맥, base 과적합
CoCoOp	context+Meta-Net	이미지별 문맥, 느림
Pixel	공통 픽셀 패턴	입력 공간, 전 이미지 공통
VPT	visual tokens+head	임베딩 공간 shallow/deep
MaPLe	양쪽 deep prompt+F	text→vision coupling
Tip-Adapter	feature/label cache	추가 gradient 학습 없음
FLYP	image+text encoder	둘 다 FT, 대조 목표 유지

CoOp·CoCoOp·Pixel·VPT·MaPLe는 pretrained backbone 동결. VPT는 task head도 학습. Tip은 labeled few-shot 데이터 필요.

CoOp / CoCoOp / MaPLe를 혼동하지 않기

CoOp: $t_k=[v_1\ldots v_M, \text{CLASS}_k]$. image/text encoder 고정, 문맥만 class CE로 학습. 길이 이득 체감·자연어 해석 어려움. **도메인 전이≠novel class 일반화.**

CoCoOp: $\pi=h_\theta(f(x))$, $v_m(x)=v_m+\pi$
$p(k|x)\propto\exp[\cos(f(x),g(t_k(x)))/\tau]$

Meta-Net이 **이미지 특징**에서 조건부 토큰 생성. novel/전이↑, 이미지마다 text encoding→느림. **MaPLe**: vision+language 여러 층 prompt, $P_I^V=F_I(P_I^T)$, F=linear projection. CoCoOp는 image→text, MaPLe는 text prompt→vision prompt.

VPT: shallow=첫 층 입력만, deep=여러 층. **FLYP**: label→caption, 사전학습과 **같은 image–text contrastive objective**로 전체 FT. image+linear head class CE와의 mismatch 줄임.

Tip: query=test 특징, key=few-shot 이미지 특징 F, value=one-hot L. $\mathbf{A=\exp[-\beta(1-fF^T)]}$, logits=αAL+기존 CLIP logits.

일반화 평가 3축

Base→novel: 같은 dataset의 새 클래스. **Cross-dataset**: 다른 dataset. **Domain generalization**: 같은 과제의 분포 변화. 균형 지표 **HM=2BN/(B+N)**(보충식).

04 · Open-vocabulary detection

3강 pp.55–65

Image 분류→region 탐지→pixel 분할. **ViLD**=Vision and Language Knowledge Distillation. **Class-agnostic localization**과 **언어 기반 classification** 분리.

ViLD-Text: region↔base text embedding, **CE**.
ViLD-Image: region feature가 CLIP crop feature를 모방, **L1 distillation**. Region feature **L2 정규화**와 **L1 loss** 구별.

추론: region↔base+novel text 비교. 새 카테고리는 **text embeddings 교체**. LVIS rare=novel, $\mathbf{AP_r}$ 평가. 색·속성으로 어휘 확장.

Learning to Name Classes=문맥 대신 클래스명 표현 최적화. **HPS v2**=생성 이미지의 사람 선호 학습·예측·평가.

05 · Transformer·Tokenizer

4강 pp.6–27

Transformer layer=**attention+FFN+LayerNorm+residual**. Decoder는 미래 누출을 causal mask로 차단.

$\text{Attn}(Q,K,V)=\text{softmax}(QK^T/\sqrt{d_k}+M)V$
$M_{ij}=0\ (j\le i)$, $\mathbf{-\infty\ (j>i)}$
$p(x_{1:T})=\prod_t p(x_t|x_{<t})$

미래 score 0만 넣으면 softmax weight≠0. **−∞→확률 0.** 학습은 mask로 병렬, 생성은 autoregressive 순차. Greedy는 매번 최고 토큰, 전체 최고 문장 보장 X.

문자열→tokenizer→**ID**→embedding lookup→LM. ID≠의미 벡터. $\mathbf{E\in\mathbb{R}^{d\times|V|}}$, 파라미터=d|V|. 큰 단위: sequence↓/어휘↑. Subword는 word 효율+character coverage 절충, 항상 형태소 X. Zipf: 빈도∝1/순위.

06 · MLLM / LLaVA

4강 pp.30–57

Vision encoder→connector→LLM+instruction. CLIP-ViT-L/14의 **penultimate patch tokens**→projector→LLM 입력. 초기 projector=linear, 1.5=MLP.

왜 penultimate? 최종 CLS에 대조 감독, 최종 patch output 직접 감독 부족. 공간·세부 보존. 모든 patch가 학습 안 됐다는 뜻 X.

데이터: caption+object/box 텍스트→text-only GPT가 지시·답 생성 **→(image,instruction,answer)**. GPT가 raw pixel을 보는 방식 X. Next-token pretrain≠instruction following.

단계	Vision	Proj.	LLM
S1 feature alignment	동결	학습	동결
S2 instruction tuning	**동결**	학습	학습

$L=-\Sigma_t\log\ p(a_t|\text{image},\text{instruction},a_{<t})$

시각 조건 아래 **답변 언어 토큰**의 AR loss. S1 595K pairs, S2 Instruct-158K(58K 대화/23K 묘사/77K 추론).

07 · Vision의 세 문제

4강 pp.61–94

① **Encoder**: 강의 이해 과제에서 CLIP/SigLIP가 유리. **Multi-crop**=고정 encoder로 고해상도; 576→2880 토큰. **VCoder**=seg/depth 추가.

CLIP-blind pair: CLIP cosine>.95, DINOv2<.6→**MMVP**. CLIP=의미 강점/세부 약점. **MoF**는 CLIP+DINOv2 상보적 특징(I-MoF 세부↑).

② **Token 비용**: attention $\mathbf{O(L^2)}$.
Q-Former=정한 수 query로 압축.
Concat→projection=이웃 4→1.
PruMerge=중요 sample→kNN cluster→weighted average. **토큰 25%만 사용**(25% 감소 X).
UI graph=구조적 중복, **selection+원위치 보존**.

③ **SoM**=Set-of-Mark. **의미 region 분할+말로 참조 가능한 mark**→grounding. 도구 SEEM/Semantic-SAM/SAM. 작은→큰 region overlay, 이전 region 제외. 가중치 학습보다 입력 표시 방식.

마지막 함정: S2 vision 학습 X / SigLIP 음성 없음 X / Tip 데이터 없음 X / CoOp=CoCoOp X / SoM=VPT 학습토큰 X.